



灵境造片厂

使用教学与 API 接口说明

这份文档面向首次安装用户和接口接入人员。客户端、AI 运行环境、模型和用户数据彼此分离；安装客户端后可一键拉取运行环境，只有网络失败时才需要手动下载。

项目主页	https://github.com/Yaro-lu/API
客户端版本	1.0.1
支持系统	Windows 10 22H2 / Windows 11, 64 位
支持硬件	NVIDIA RTX 20 系列或更高, 显存 8GB 或以上; CUDA 13 环境要求 R580 或更高驱动

Yaro-lu | 本地 AI workflow 服务

1. 安装与第一次启动

- 1. 双击轻量安装包，按提示完成安装。安装过程不需要管理员权限，也不会安装模型。
- 2. 安装完成后，桌面会出现两个使用同一 Logo 的入口：“灵境造片厂”用于启动客户端，“灵境造片厂示例页”用于第一次体验接口。
- 3. 客户端界面可以立即打开；此时文字、图片和视频生成仍不可用，因为大型 AI 运行环境独立分发。
- 4. 进入“模型与环境”，点击“一键修复”。客户端会自动拉取环境包，并使用内置 SHA256 校验，通过后直接安装。
- 5. 只有自动拉取失败时，客户端才会显示“自动修复失败”弹窗。可复制 GitHub 地址，手动下载环境包，再选择本地环境包完成安装。

运行环境包文件名：**runtime-nvidia-rtx20plus-cu130-v1.0.0.7z**
项目主页：<https://github.com/Yaro-lu/API>

安装目录中的主要入口

名称	用途
灵境造片厂	正式启动入口，使用项目 Logo
灵境造片厂示例页.html	本地纯前端新手页面；填写 URL 和 Key 后自动检测模型并调用生成
灵境造片厂使用教学.pdf	当前使用教学与接口说明
models	用户模型目录，更新客户端时保留
outputs	生成结果目录
workflows	内置或导入的工作流定义

2. 环境、模型与 workflow

运行环境

运行环境包含便携 Python、ComfyUI、Torch/CUDA 和 Cloudflared。客户端会先校验环境包名称、SHA256 和目录结构，再事务替换环境目录。模型、workflow 和生成结果不会因为环境修复而删除。

官方环境包版本、文件名、下载地址和 SHA256 固定在客户端发布清单中。需要使用授权镜像时，可以在 runtime/config.local.txt 的 [runtime] 区域修改 download_url；镜像不能改变客户端内置的文件名和 SHA256 校验。

模型

模型统一放在安装根目录的 `models` 文件夹。优先使用可信来源的 safetensors 或 GGUF 文件，不要导入来源不明的传统 PyTorch checkpoint。

workflow

每个 workflow 至少包含 manifest.json 和 workflow.json。manifest.json 定义公开调用名称、输入参数、输出类型和模型依赖。导入后应在“workflow”页面确认状态为“可以使用”。

推荐操作顺序

1. 安装或修复运行环境，并执行“检查环境”。
2. 导入 workflow 所需模型，然后点击“重新检查”。
3. 在 workflow 页面选择默认 workflow。
4. 回到控制台启动后台服务，复制 URL 和 API Key。
5. 打开桌面或安装目录中的“灵境造片厂示例页”，填写 URL 和 Key，连接后选择已检测到的文字、图片或视频模型。

客户端更新只替换程序文件；运行环境、模型、配置、日志和生成结果独立保存。卸载时可能保留可变数据，删除前请先备份。

3. API 接入基础

新手示例页

“灵境造片厂示例页.html” 完全保存在本机，是一个不依赖额外服务的纯前端页面。它只会把你填写的 URL、API Key 和生成参数发送给已经启动的灵境造片厂客户端；连接后会读取客户端模型列表，并按文字、图片、视频自动分类。

推荐第一次使用先打开示例页：输入客户端控制台显示的 URL 与 API Key，点击“连接并检测模型”，在“图片”分类输入画面描述后开始生成；视频分类需要选择首帧和尾帧图片。API Key 仅保存在当前浏览器会话中，关闭浏览器后需要重新填写。

地址与鉴权

控制台会显示公网或本地 BASE_URL，以及生成接口使用的 API_KEY。除 `/healthz` 外，业务接口通常需要在请求头中携带 Bearer Token。本机地址可使用 HTTP；远程或公网地址必须使用 HTTPS，示例页会拒绝向远程明文 HTTP 地址发送 Key。

Authorization: Bearer API_KEY
Content-Type: application/json

主要接口

方法	路径	用途
GET	/healthz	免鉴权的最小存活状态
GET	/v1/status	客户端、环境和后台服务完整状态
GET	/v1/models	当前可调用模型列表
GET	/v1/workflows	工作流与公开调用名称列表
POST	/	运行当前选中的默认工作流
POST	/ {workflow_alias}	按公开名称运行指定工作流
POST	/v1/chat/completions	OpenAI 风格文字生成接口
POST	/api/v3/images/generations	火山/即梦风格图片生成接口
POST	/v1/workflows/run/{workflow_id}	按工作流 ID 提交生成任务
GET	/v1/tasks/{task_id}	查询异步任务进度和结果
GET	/v1/files/{task_id}/{filename}	下载任务生成文件

不要把 API Key 写入公开网页、代码仓库、聊天截图或日志。公网 URL 是互联网入口，应和 API Key 一起妥善保存。

4. 调用示例与异步任务

运行默认工作流

```
curl -X POST "BASE_URL/" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"一只在窗边晒太阳的猫\"}"
```

OpenAI 风格文字接口

```
curl -X POST "BASE_URL/v1/chat/completions" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"model\":\"qwen3\",\"messages\":[{\"role\":\"user\",\"content\":\"写一段产品介绍\"}]}"
```

图片生成兼容接口

```
curl -X POST "BASE_URL/api/v3/images/generations" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"电影感城市夜景\",\"response_format\":\"url\"}"
```

异步任务流程

1. 生成接口返回 task_id。
2. 轮询 GET /v1/tasks/{task_id}，直到状态变为完成或失败。
3. 从响应读取文件名或 URL。
4. 调用 GET /v1/files/{task_id}/{filename} 下载结果。

5. 常见问题与安全说明

客户端能打开，但不能生成

轻量客户端只负责界面和环境维护。请先下载并安装独立运行环境包，再补齐 workflow 要求的模型。

一键修复拉取失败怎么办

失败弹窗会显示网络或下载错误，并提供可复制的 GitHub 地址。在项目 Releases 下载 7z 环境包，然后回到客户端选择本地环境包；客户端会使用内置 SHA256 校验。

环境检查提示 NVIDIA 驱动过旧

CUDA 13 运行环境要求使用 R580 或更高驱动。更新驱动后重启电脑，再点击“检查环境”。

接口返回 401 或 403

检查 Authorization 请求头是否使用 `Bearer API\_KEY`，并确认复制的是生成接口 Key，而不是本机管理 Key。

接口能访问但 workflow 失败

在 workflow 页面查看缺失模型和公开参数；确认模型文件完整，默认 workflow 已选中，ComfyUI 状态正常。

更新客户端会不会删除模型

不会。程序、运行环境、模型和用户数据分离。重要模型和输出仍建议定期备份。

项目主页：<https://github.com/Yaro-lu/API>

建议始终从项目主页或明确授权的镜像获取安装包和环境包；客户端会用内置 SHA256 验证环境包。